法律声明

- 本课件包括：演示文稿，示例，代码，题库，视频和声音等，小象学院拥有完全知识产权的权利；只限于善意学习者在本课程使用，不得在课程范围外向任何第三方散播。任何其他人或机构不得盗版、复制、仿造其中的创意，我们将保留一切通过法律手段追究违反者的权利。

- 课程详情请咨询
  - 微信公众号：大数据分析挖掘
  - 新浪微博：ChinaHadoop

传统神经网络

主讲人： 李伟

纽约城市大学博士

主要研究深度学习，计算机视觉，人脸计算

多篇重要研究文章作者，重要会议期刊审稿人

微博ID：weightlee03（相关资料分享）

GitHub ID：wiibrew （课程代码发布）

结构

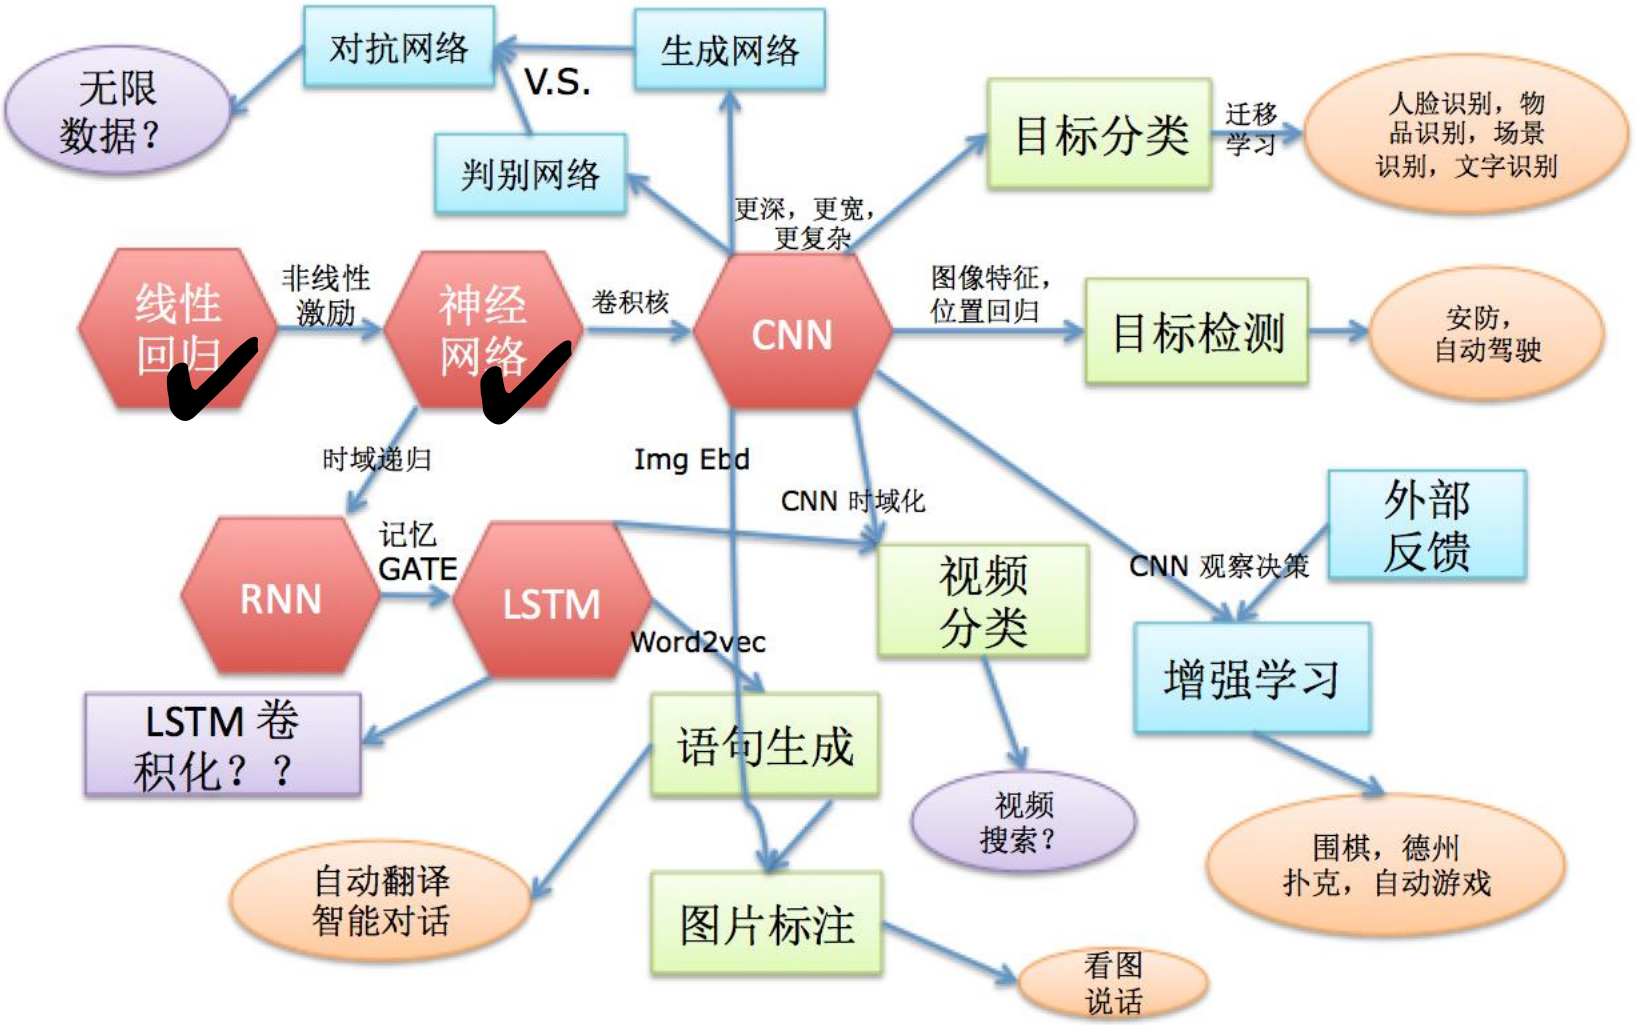
对抗网络
生成网络
V.S.
无限数据？
判别网络
更深，更宽，更复杂
目标分类
迁移学习
人脸识别，物品识别，场景识别，文字识别
线性回归
非线性激励
神经网络
卷积核
CNN
图像特征，位置回归
目标检测
安防，自动驾驶
时域递归
Img Ebd
CNN 时域化
外部反馈
RNN
记忆GATE
LSTM
视频分类
CNN 观察决策
Word2vec
增强学习
LSTM 卷积化？？
语句生成
视频搜索？
围棋，德州扑克，自动游戏
自动翻译智能对话
图片标注
看图说话

提纲

- 1. 神经网络起源：线性回归
- 2. 从线性到非线性
- 3. 神经网络的构建
- 4. 神经网络的“配件”

期待目标

- 1. 了解从线性到非线性回归的转化
- 2. 明白如何构建神经网络，了解不同激励函数的区别联系
- 3. 掌握“配件”对神经网络性能的影响（损失函数，学习率，动量，过拟合），会“调参”
- 4. 明白本节所有的[面试题]

提纲

- 1. 神经网络起源：线性回归
- 2. 从线性到非线性
- 3. 神经网络的构建
- 4. 神经网络的“配件”

线性回归

- 概念：线性关系来描述输入到输出的映射关系

- 应用场景：

网络分析

银行风险分析

基金股价预测

天气预报

线性回归

一个线性回归问题

目标方程： $y=ax_1+bx_2+cx_3+d$

参数： $m=[a,b,c,d]$

数据： $[(x_{1,1},x_{2,1},x_{3,1}), (x_{1,2},x_{2,2},x_{3,2}), \ldots(x_{1,n},x_{2,n},x_{3,n})]$

$[y_1,y_2\ldots..y_n]$

预测： $\hat{y}_t = ax_{1,t}+bx_{2,t}+cx_{3,t}+d$

目标： $\text{minimize } (\hat{y}_t - y_t)$

线性回归

- 优化方法：梯度下降

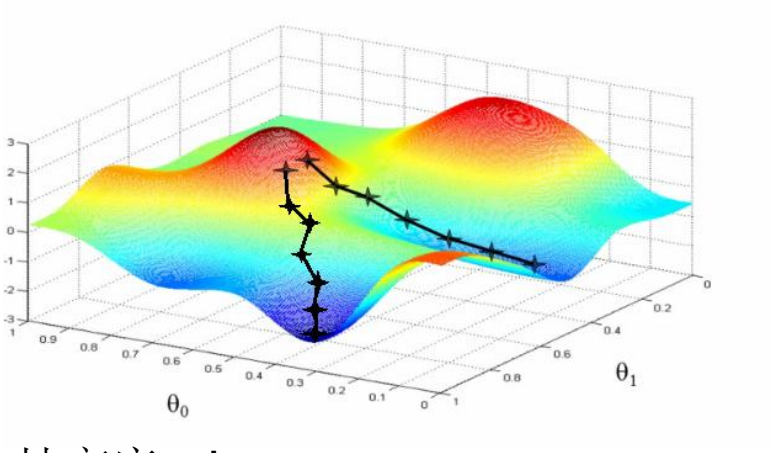

山坡高度：Loss
地面位置：参数
山坡最低点：Loss minimal
最低点位置：目标参数
怎么到达：下坡方向，梯度下降
怎么找方向：高度对地面关系导数

- 模型参数

当前 $m_0 = [a_0, b_0, c_0, d_0]$

每一步 Δm?

参数：m=[a,b,c,d]

线性回归

- 梯度下降：梯度计算

$$Loss=ax_{1,t}+bx_{2,t}+cx_{3,t}+d-y$$

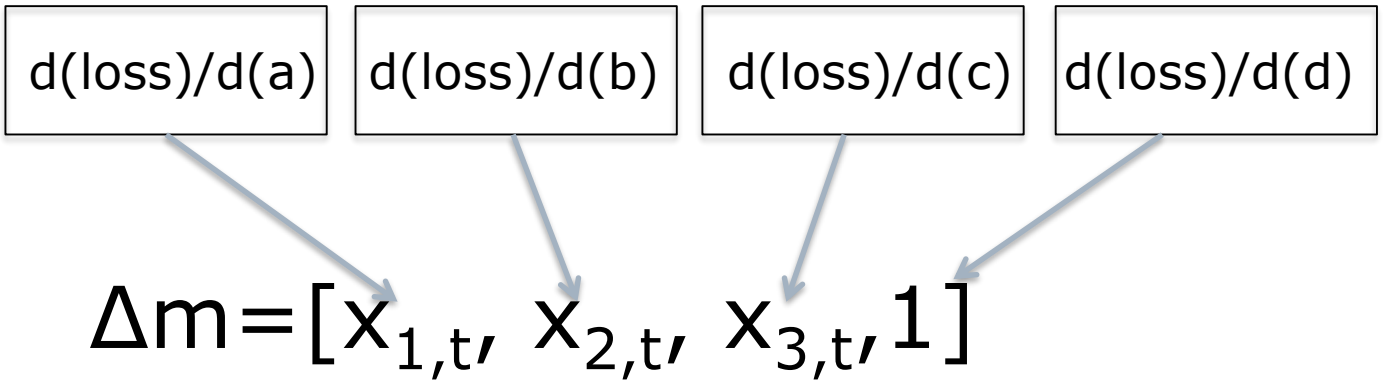

- 梯度下降：参数更新 $m:=m-\eta\Delta m$

线性回归

梯度下降法总结：

随机初始化参数

开启循环：t=0，1，2。。

带入数据求出结果$\hat{y}_t$

与真值比较得到$loss = y - \hat{y}_t$

对各个变量求导得到Δm

更新变量m

如果loss足够小或t循环结束，停止

线性回归

- 输出+

- 能否同时预测多个目标？

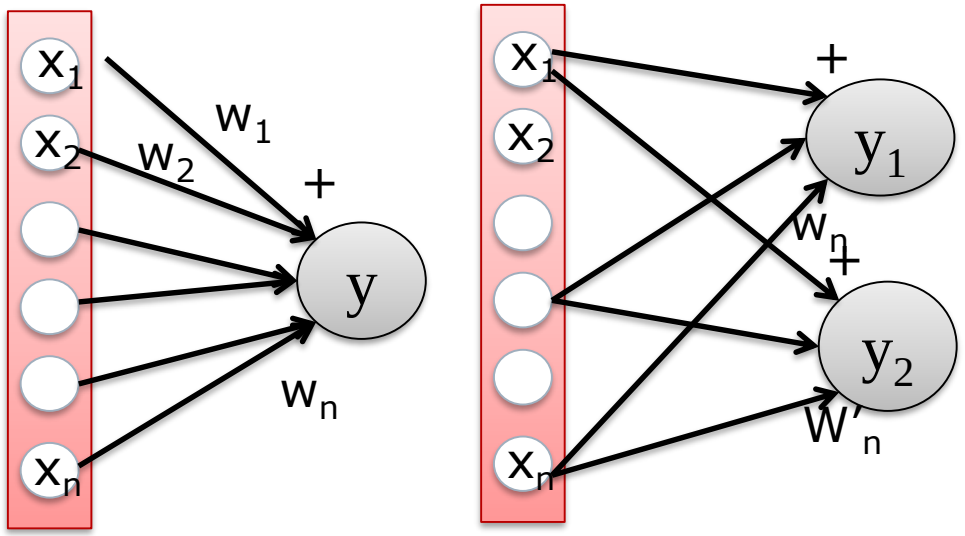

线性回归

输出 +

- 能否同时预测多个目标？

多目标学习，通过合并多个任务loss，一般能够产生比单个模型更好的效果。

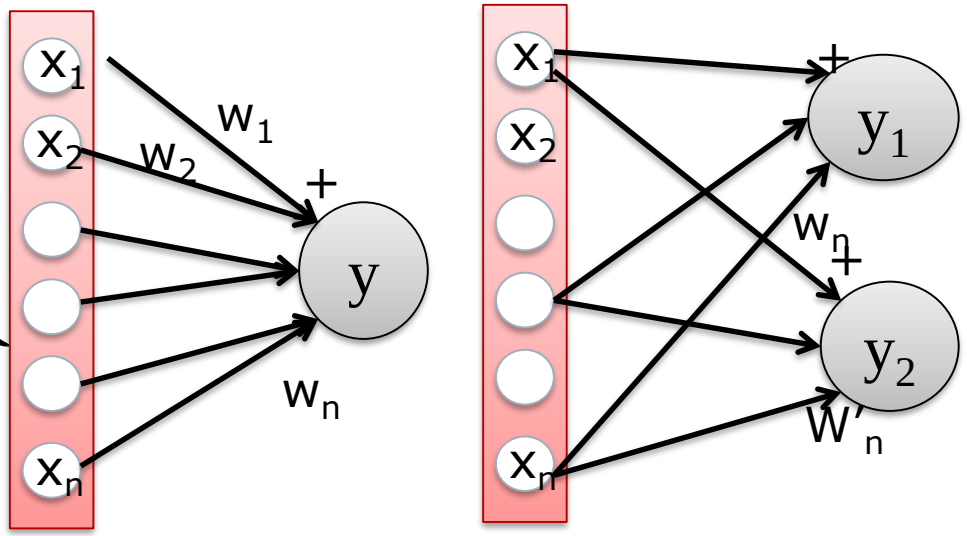

线性回归

局限

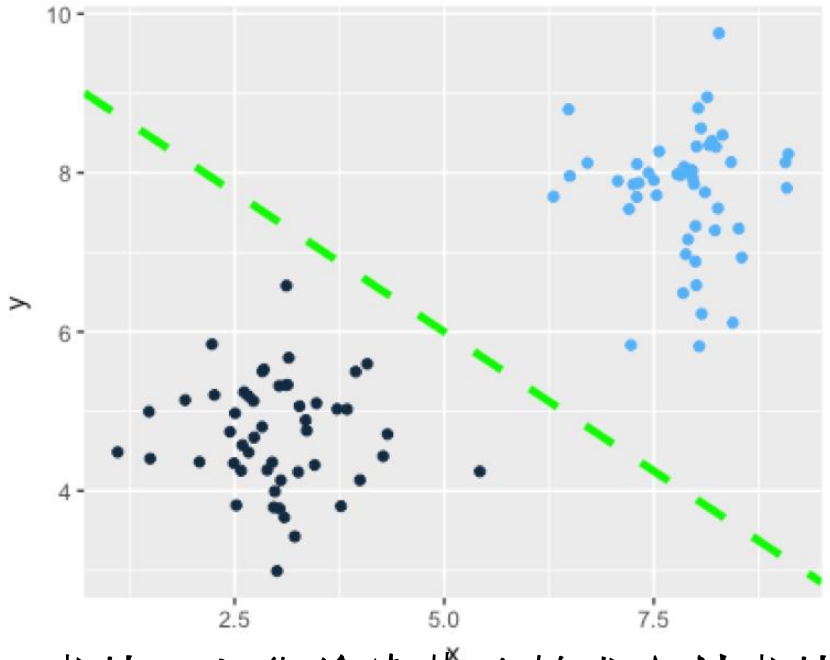

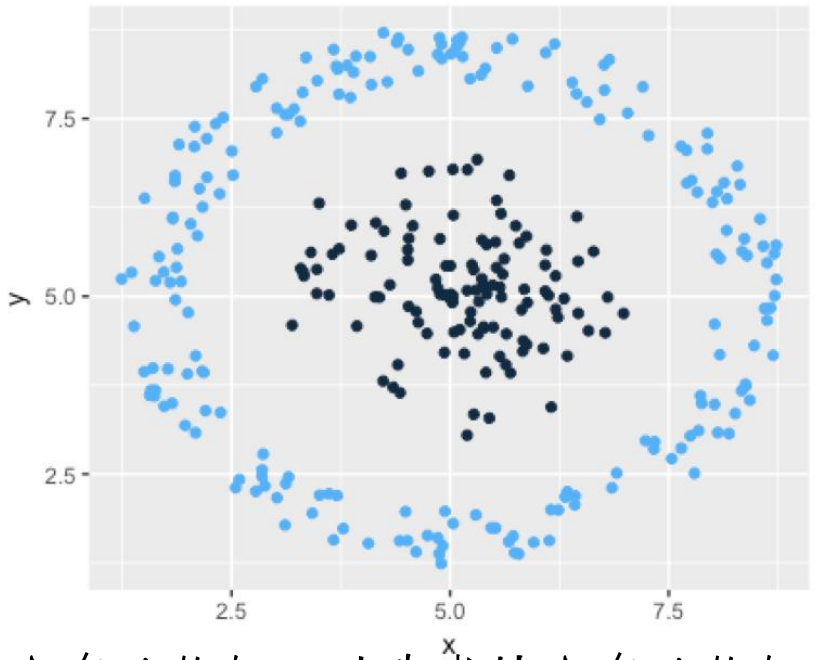

线性回归能够清楚的描述分割线性分布的数据，对非线性分布的数据描述较弱

提纲

- 1. 神经网络起源：线性回归
- 2. 从线性到非线性
- 3. 神经网络的构建
- 4. 神经网络的“配件”

从线性到非线性

- 非线性激励

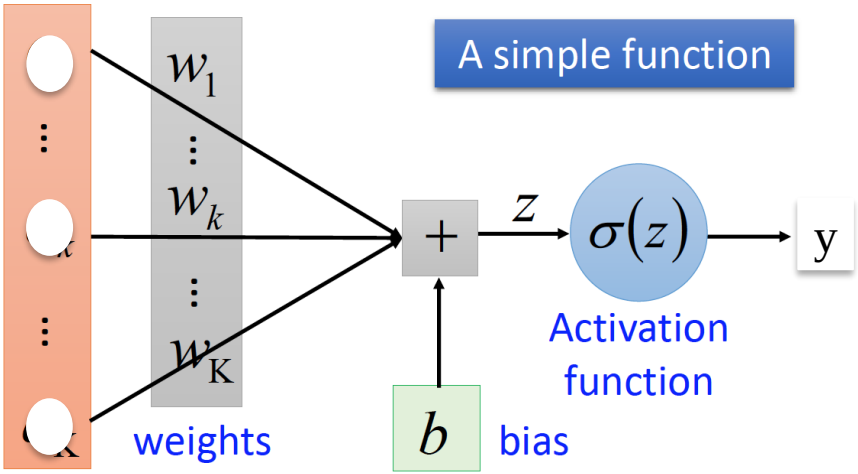

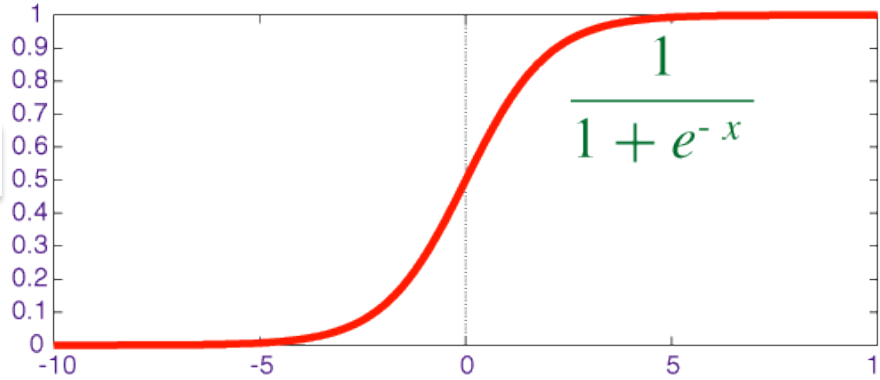

- 考量标准：
- 1.正向对输入的调整
- 2.反向梯度损失

从线性到非线性

- 常用的非线性激励函数

- Sigmoid，
- 函数效果，导数
- 优点，缺点

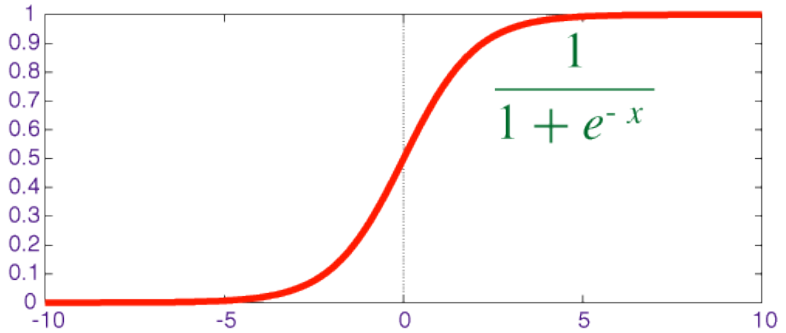

$$y(x) = sigmoid(x) = \frac{1}{1+e^{-x}}$$

$$y(x)' = y(x)(1 - y(x)))$$

从线性到非线性

- 常用的非线性激励函数

- Sigmoid，
- 函数效果，导数
- 优点，缺点

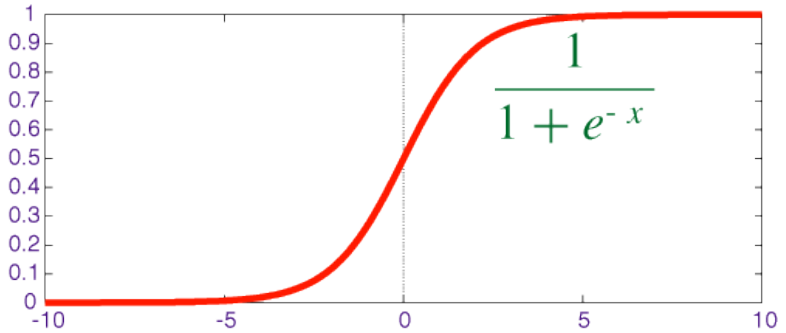

$$y(x) = sigmoid(x) = \frac{1}{1+e^{-x}}$$

$$y(x)' = y(x)(1-y(x)))$$

将输入数据映射到 [0，1]

梯度下降非常明显，至少减少75%

从线性到非线性

- 常用的非线性激励函数

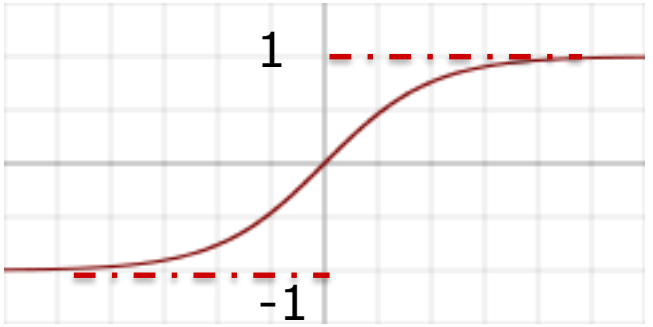

- tahn，
- 函数效果，导数
- 优点，缺点

$$f(x) = \tanh(x) = \frac{2}{1 + e^{-2x}} - 1$$

$$f'(x) = 1 - f(x)^2$$

从线性到非线性

- 常用的非线性激励函数

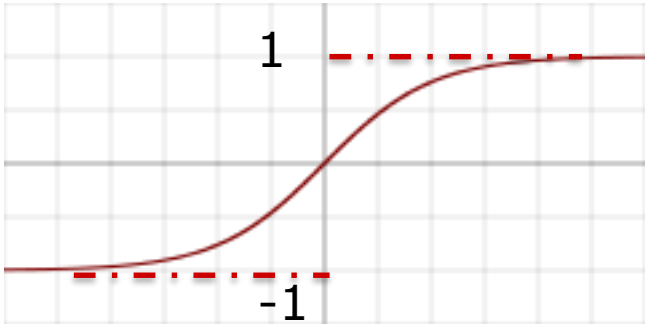

- tahn，
- 函数效果，导数
- 优点，缺点

$$f(x) = \tanh(x) = \frac{2}{1 + e^{-2x}} - 1$$

$$f'(x) = 1 - f(x)^2$$

将输入数据映射到 $[-1, 1]$

梯度损失明显

从线性到非线性

- 常用的非线性激励函数

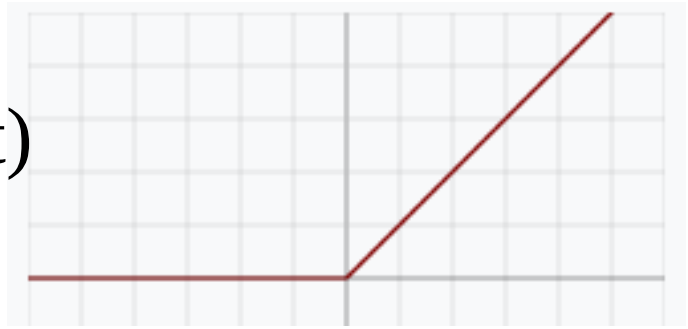

- ReLU(Rectified linear unit)
- 函数效果，导数
- 优点，缺点

$$f(x) = \begin{cases} 0 & \text{for} \quad x < 0 \\ x & \text{for} \quad x \geq 0 \end{cases}$$

$$f'(x) = \begin{cases} 0 & \text{for} \quad x < 0 \\ 1 & \text{for} \quad x \geq 0 \end{cases}$$

从线性到非线性

- 常用的非线性激励函数

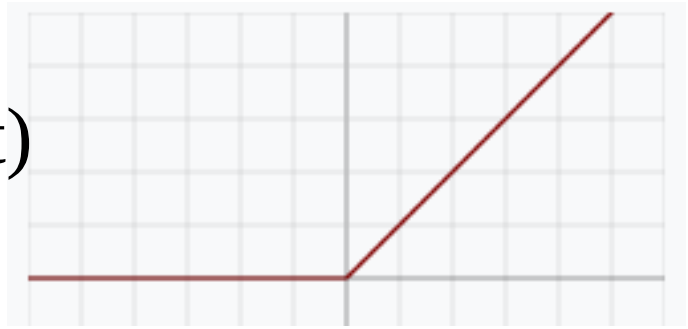

- ReLU(Rectified linear unit)
- 函数效果，导数
- 优点，缺点

$$f(x) = \begin{cases} 0 & \text{for} \quad x < 0 \\ x & \text{for} \quad x \geq 0 \end{cases}$$

正向截断负值，损失大量特征

$$f'(x) = \begin{cases} 0 & \text{for} \quad x < 0 \\ 1 & \text{for} \quad x \geq 0 \end{cases}$$

反向梯度没有损失

从线性到非线性

- 常用的非线性激励函数

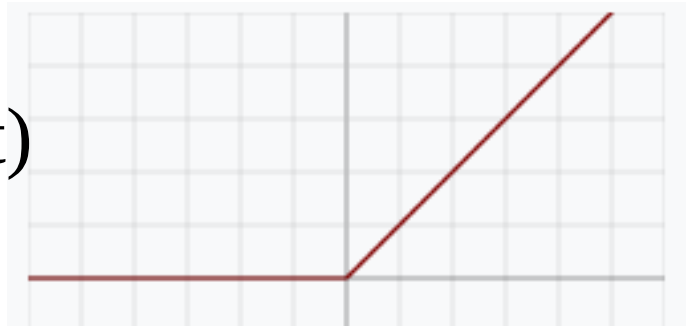

- ReLU(Rectified linear unit)
- 函数效果，导数
- 优点，缺点

$$f(x) = \begin{cases} 0 & \text{for} \quad x < 0 \\ x & \text{for} \quad x \geq 0 \end{cases}$$

正向截断负值，损失大量特征

为什么还用？

$$f'(x) = \begin{cases} 0 & \text{for} \quad x < 0 \\ 1 & \text{for} \quad x \geq 0 \end{cases}$$

反向梯度没有损失

从线性到非线性

- 常用的非线性激励函数

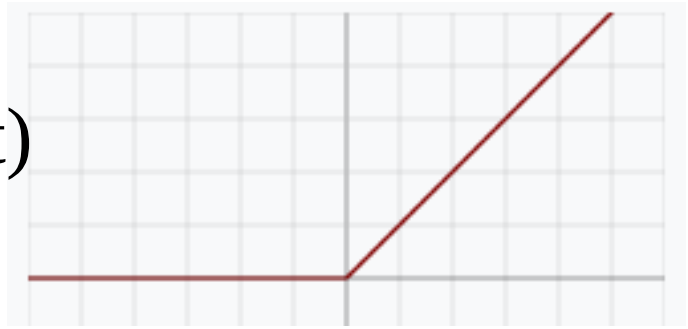

- ReLU(Rectified linear unit)
- 函数效果，导数
- 优点，缺点

$$f(x) = \begin{cases} 0 & \text{for} \quad x < 0 \\ x & \text{for} \quad x \geq 0 \end{cases}$$

正向截断负值，损失大量特征

为什么还用？特征足够多

$$f'(x) = \begin{cases} 0 & \text{for} \quad x < 0 \\ 1 & \text{for} \quad x \geq 0 \end{cases}$$

反向梯度没有损失

从线性到非线性

- 常用的非线性激励函数

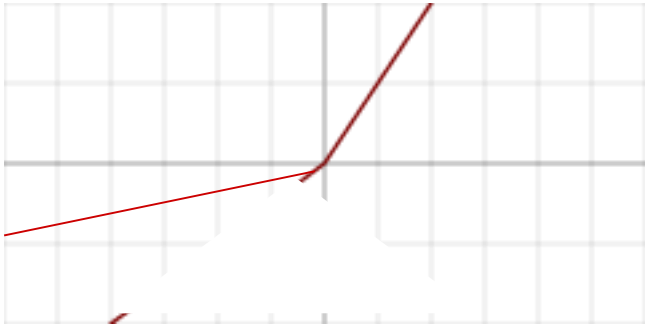

- Leaky ReLU(Rectified linear unit)
- 函数效果，导数
- 优点，缺点

$$f(x) = \begin{cases} 0.01x & \text{for} \quad x < 0 \\ x & \text{for} \quad x \geq 0 \end{cases}$$

$$f'(x) = \begin{cases} 0.01 & \text{for} \quad x < 0 \\ 1 & \text{for} \quad x \geq 0 \end{cases}$$

保留更多参数，少量梯度反向传播

为什么不变成y=x？

从线性到非线性

- 常用的非线性激励函数

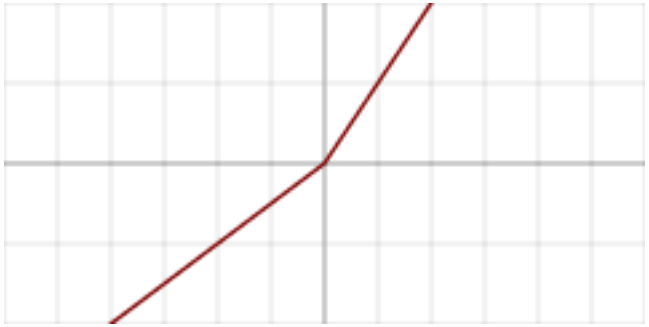

- Leaky ReLU(Rectified linear unit)
- 函数效果，导数
- 优点，缺点

$$f(x) = \begin{cases} 0.01x & \text{for} \quad x < 0 \\ x & \text{for} \quad x \geq 0 \end{cases}$$

$$f'(x) = \begin{cases} 0.01 & \text{for} \quad x < 0 \\ 1 & \text{for} \quad x \geq 0 \end{cases}$$

保留更多参数，少量梯度反向传播

为什么不变成y=x？ 线性了

从线性到非线性

- 神经元－神经网络

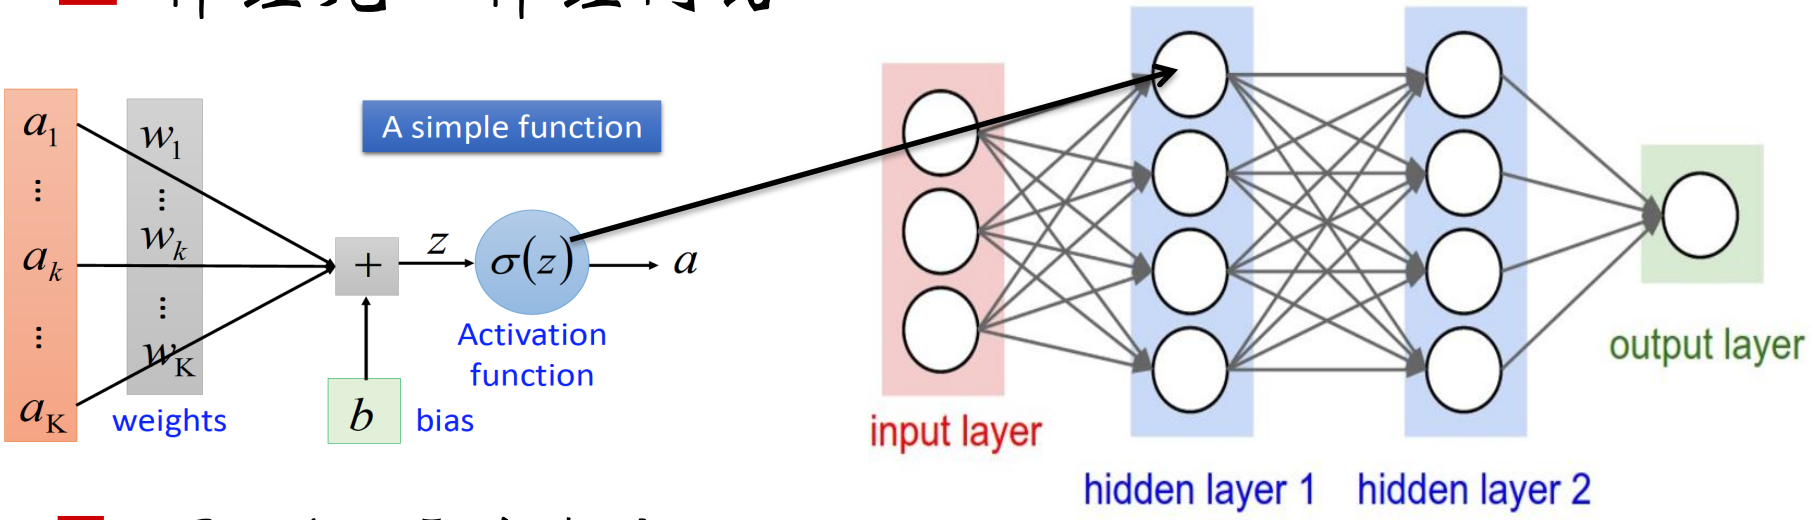

- [面试题] 有线性回归网络吗？

从线性到非线性

神经元－神经网络

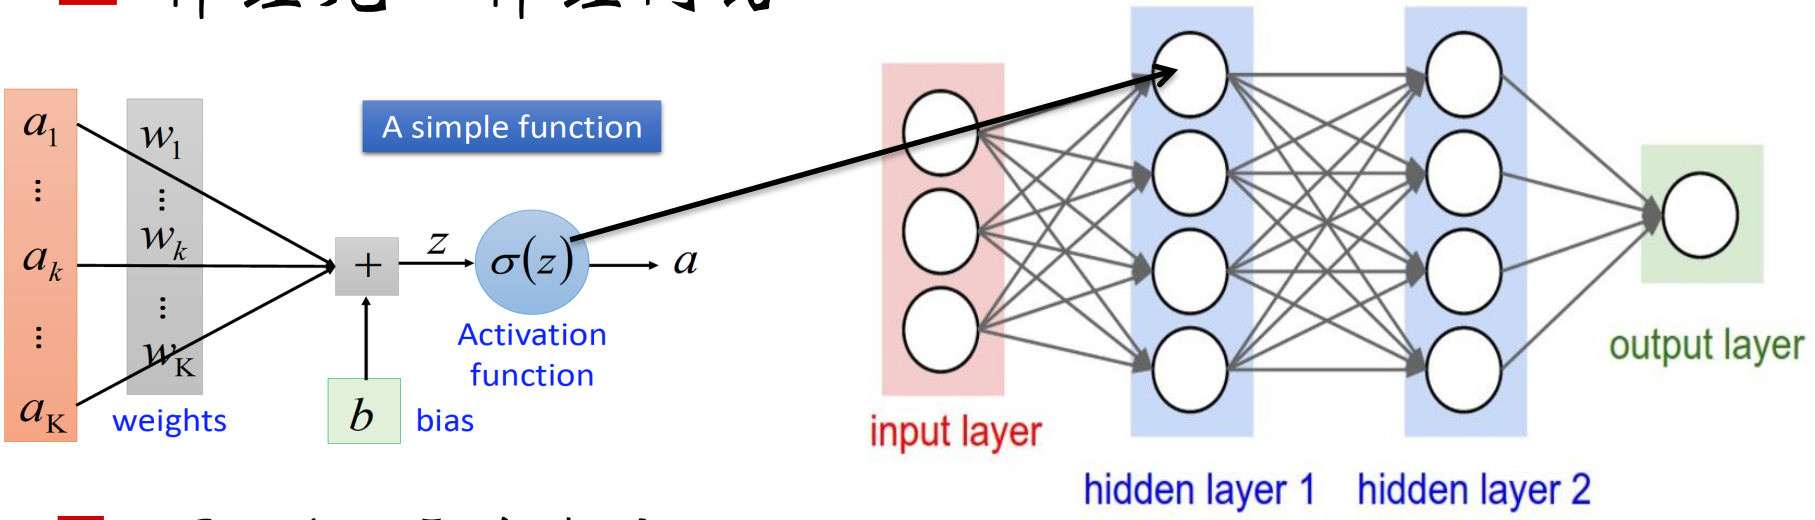

[面试题] 有线性回归网络吗？

并没有。。

$$X_1 = W_0 \cdot X_0, X_2 = W_1 \cdot X_1, Y = W_2 \cdot X_2$$

$$Y = W_2 \cdot W_1 \cdot W_0 \cdot X_0 = W_3 \cdot X_0$$

提纲

- 1. 神经网络起源：线性回归
- 2. 从线性到非线性
- **3. 神经网络的构建**
- 4. 神经网络的“配件”

神经网络构建

神经元的“并联”和“串联”

- 从第一层神经网络到最终输出，每一个神经元的数值由前一层神经元数值，神经元参数W，b以及激励函数共同决定

第n+1层第k个神经元的方程可由公式表示为：

$$z_{n+1,k} = \sum_{i=1}^{m} W_{n,k,i} \cdot x_{n,i} + b_{n,k}$$

$$y_{n+1,k} = \frac{1}{1 + e^{-z_{n+1,k}}}$$

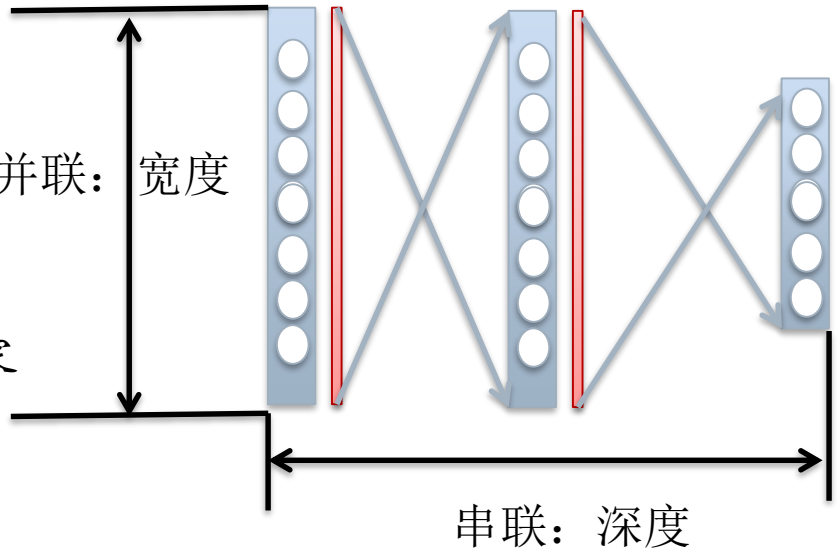

在这里，m表示第n层神经网络的宽度，n为当前神经网络的深度

神经网络构建

神经网络优化

- 链式法则

（下一讲主要内容）

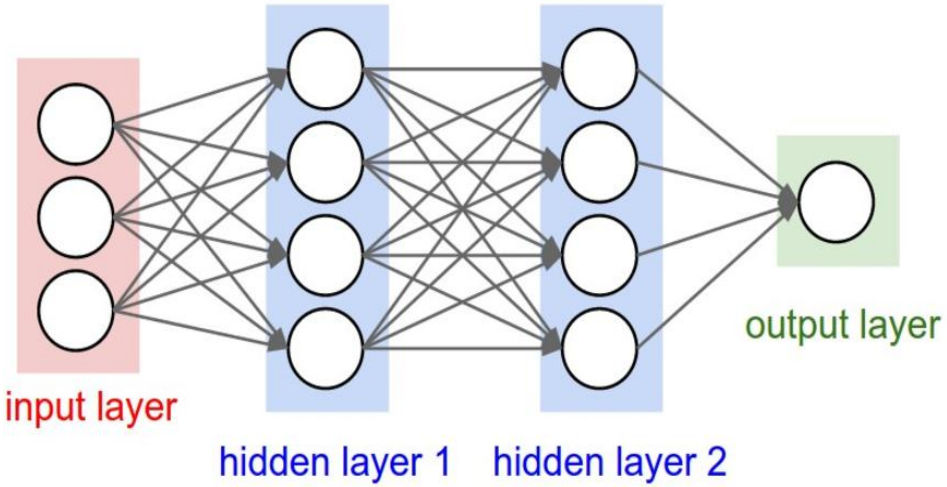

- 计算梯度

output->last layer　　Loss-->Δy_n

layer->layer　　Δy_n-->Δx_n

layer->parameter　　Δy_n-->Δw_n

怎么计算 Δw_i？ Δy_i, Δx_{i+1}, ….Δy_n,

神经网络构建

神经网络求导 – TensorFlow实现

```
data = tf.placeholder(tf.float32)
var = tf.Variable(...)
loss = some_function_of(var, data)
var_grad = tf.gradients(loss, [var])


sess = tf.Session()
var_grad_val = sess.run(var_grad, feed_dict={data: ...})
```

神经网络构建

神经网络实例分析：MINIST 神经网络分类

见: course_2_tf_nn.py

结构变化影响

- “并联”宽度影响
- “串联”层数影响
- Dropout
- Learning rate

提纲

- 1. 神经网络起源：线性回归
- 2. 从线性到非线性
- 3. 神经网络的构建
- **4. 神经网络的“配件”**

神经网络的“配件”

- 1.损失函数-Loss

- 影响深度学习性能最重要因素之一。是外部世界对神经网络模型训练的直接指导。

- 合适的损失函数能够确保深度学习模型收敛

- 设计合适的损失函数是研究工作的主要内容之一

神经网络的“配件”

- 1.损失函数
- Softmax

$$\sigma(\mathbf{z})_j = \frac{e^{z_j}}{\sum_{k=1}^{K} e^{z_k}} \quad \text{for } j = 1, \ldots, K.$$

- Loss影响？

神经网络的“配件”

- 1.损失函数
- Softmax

$$\sigma(\mathbf{z})_j = \frac{e^{z_j}}{\sum_{k=1}^{K} e^{z_k}} \quad \text{for } j = 1, \ldots, K.$$

- Loss影响？

[1,2,3,4,1,2,3] ⟶ [0.024, 0.064, 0.175, 0.475, 0.024, 0.064, 0.175]

神经网络的“配件”

- 1.损失函数
- Softmax

$$\sigma(\mathbf{z})_j = \frac{e^{z_j}}{\sum_{k=1}^{K} e^{z_k}} \quad \text{for } j = 1, \ldots, K.$$

- Loss影响？

[1,2,3,4,1,2,3] ⟶ [0.024, 0.064, 0.175, 0.475, 0.024, 0.064, 0.175]

- Softmax的好处？

神经网络的“配件”

- 1.损失函数
- Softmax

$$\sigma(\mathbf{z})_j = \frac{e^{z_j}}{\sum_{k=1}^{K} e^{z_k}} \quad \text{for } j = 1, \ldots, K.$$

- Loss影响？

[1,2,3,4,1,2,3] ⟶ [0.024, 0.064, 0.175, 0.475, 0.024, 0.064, 0.175]

- Softmax的好处？

分类问题的预测结果更明显

神经网络的“配件”

- 1.损失函数
- Cross entropy

$$L(\mathbf{w}) = \frac{1}{N}\sum_{n=1}^{N} H(p_n, q_n) = -\frac{1}{N}\sum_{n=1}^{N}\left[y_n \log \hat{y}_n + (1-y_n)\log(1-\hat{y}_n)\right]$$

- Explode?->

$$Loss = -\Sigma(l \cdot \log(\frac{p+0.05}{1.05}) + (1-l)\cdot\log(\frac{1.05-p}{1.05}))$$

W. Li, F. Abtahi, Z. Zhu, Action Unit Detection with Region Adaptation, Multi-labeling Learning and Optimal Temporal Fusing. CVPR 2017.

- 用途?

神经网络的“配件”

- 1.损失函数
- Cross entropy

$$L(\mathbf{w}) = \frac{1}{N}\sum_{n=1}^{N} H(p_n, q_n) = -\frac{1}{N}\sum_{n=1}^{N}\left[y_n \log \hat{y}_n + (1-y_n)\log(1-\hat{y}_n)\right]$$

- Explode?->

$$Loss = -\Sigma(l \cdot \log(\frac{p+0.05}{1.05}) + (1-l)\cdot\log(\frac{1.05-p}{1.05}))$$

W. Li, F. Abtahi, Z. Zhu, Action Unit Detection with Region Adaptation, Multi-labeling Learning and Optimal Temporal Fusing. CVPR 2017.

- 用途?

目标为 [0，1] 区间的回归问题，以及生成

神经网络的“配件”

- 1.损失函数

自定义

- a. 看中某一个属性

单独将某一些预测值取出或赋予不同大小的参数

- b. 合并多个loss

多目标训练任务，设置合理的loss结合方式(各种运算)

- c. 神经网络融和

不同神经网络loss结合，共同loss对网络进行训练指导

神经网络的“配件”

- 2. 学习率 Learning rate

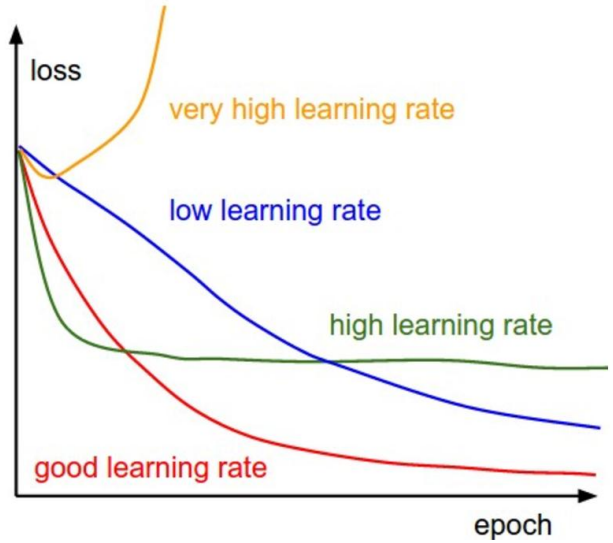

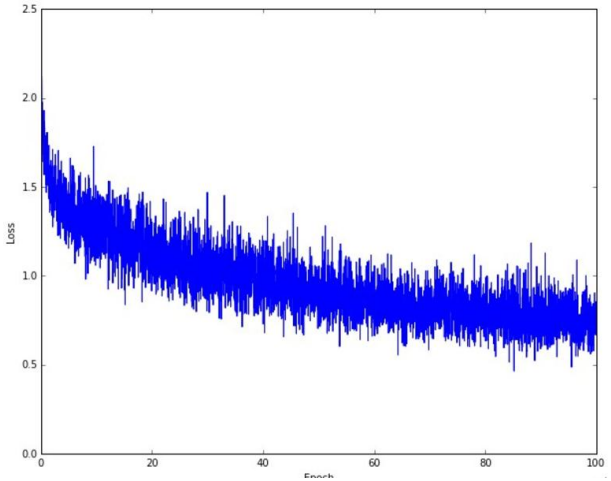

- 数值大：收敛速度快
- 数值小：精度高

神经网络的“配件”

- 2. 学习率 Learning rate
- 如何选用合适的学习率？

  1. Fixed；2. Step；

  3. Adagrad（知道定义即可）

```
# Assume the gradient dx and parameter vector x
cache += dx**2
x += - learning_rate * dx / (np.sqrt(cache) + eps)
```

  4. RMSprop

```
cache = decay_rate * cache + (1 - decay_rate) * dx**2
x += - learning_rate * dx / (np.sqrt(cache) + eps)
```

神经网络的“配件”

- 3. 动量
- 正常 `x += - learning_rate * dx`
- Why?

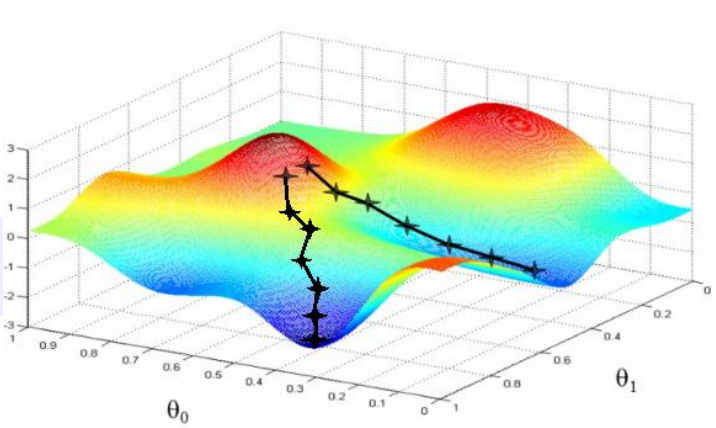

沿着已经得到的优化方向前进，不用重新找方向，只需微调

- How?

v = 0

```
# Momentum update
v = mu * v - learning_rate * dx # integrate velocity
x += v # integrate position
```

神经网络的“配件”

- 3. 动量
- 正常 `x += - learning_rate * dx`
- Why?

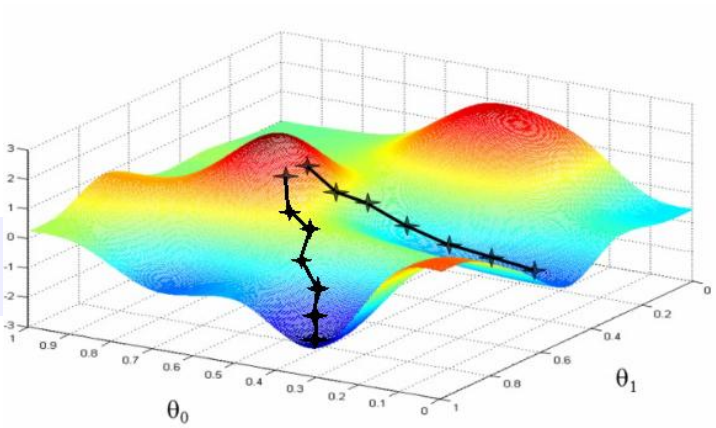

沿着已经得到的优化方向前进，不用重新找方向，只需微调

- How?

v = 0

```
# Momentum update
v = mu * v - learning_rate * dx # integrate velocity
x += v # integrate position
```

[面试题] 用动量和直接调大学习率有什么区别？

神经网络的“配件”

- 3. 动量
- 正常 `x += - learning_rate * dx`
- Why?

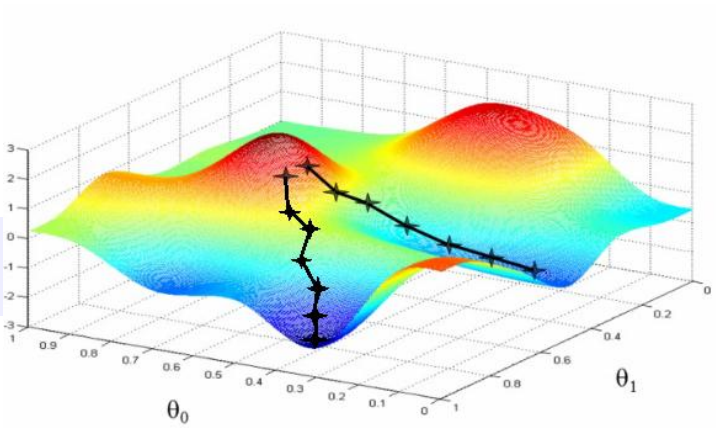

沿着已经得到的优化方向前进，不用重新找方向，只需微调

- How?

```
# Momentum update
v = mu * v - learning_rate * dx # integrate velocity
x += v # integrate position
```

[面试题] 和直接调大学习率有什么区别？

方向不同找的更准确

神经网络的“配件”

3. 动量

Nesterov 动量

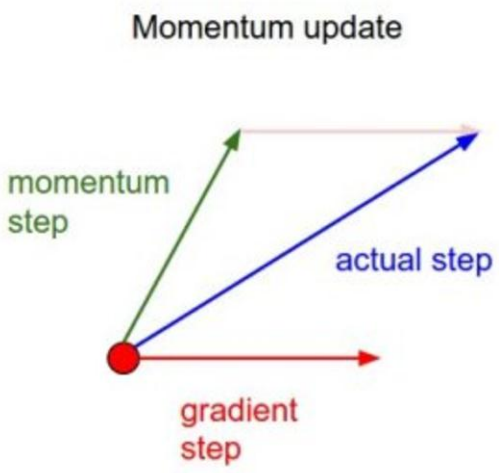

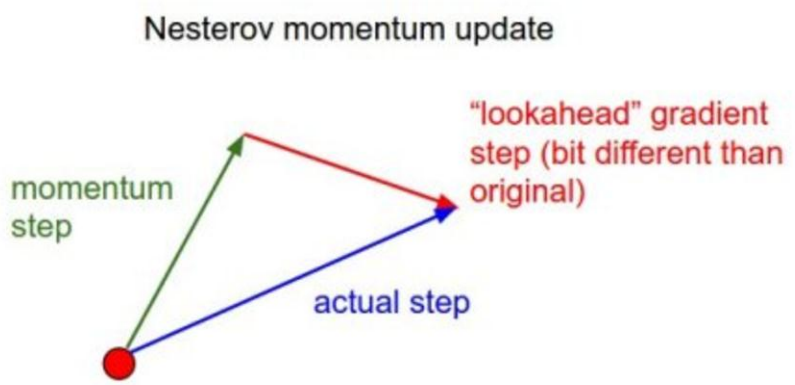

理解：新的梯度更新是在动量投射的基础上

```
x_ahead = x + mu * v
# evaluate dx_ahead (the gradient at x
v = mu * v - learning_rate * dx_ahead
x += v
```

神经网络的“配件”

4. 过拟合(Overfitting)：

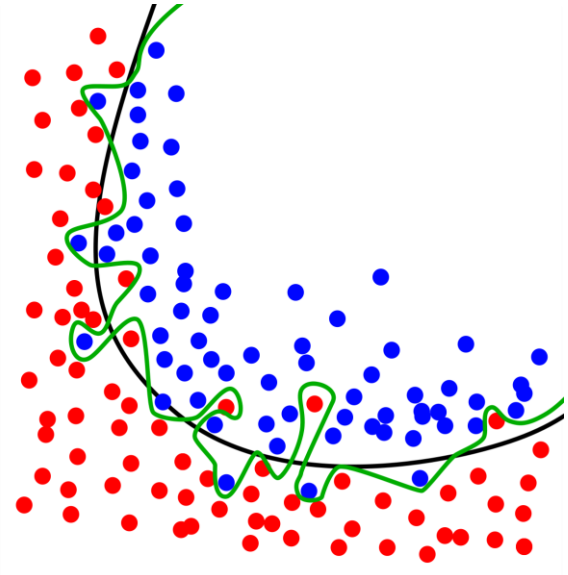

哪个参数更好？

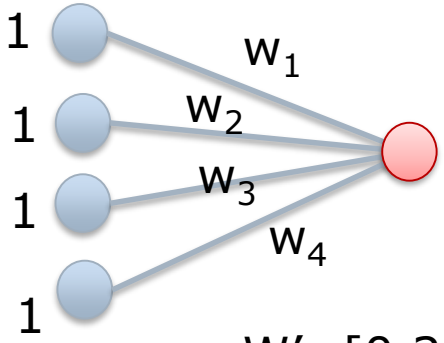

W’=[0.25,0.25,0.25.0.25]

W’’=[1,0,0,0]

神经网络的“配件”

4. 过拟合(Overfitting)：

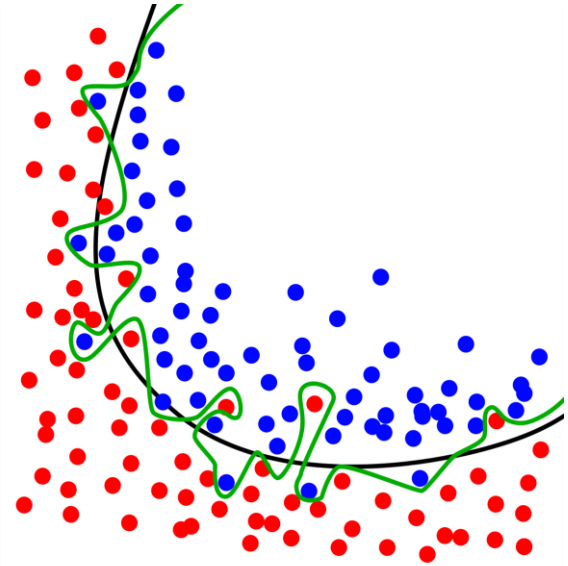

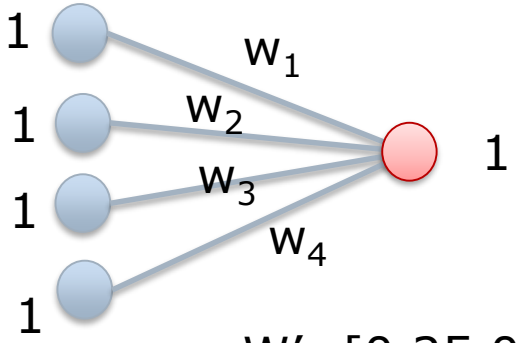

W′=[0.25,0.25,0.25.0.25]

W″=[1,0,0,0]

哪个参数更好？

如果更多的参数能够参与决策，会对输入有更高的适应性，w″更好

神经网络的“配件”

4. 过拟合---应对：

- Regularization

Before **After**

- Loss=ŷ-y;
- $\Delta w=d(Loss)/d(w)$;
- $w:=w-\eta\Delta w$;

神经网络的“配件”

4. 过拟合---应对：

- Regularization

Before	After
Loss=ŷ-y;	$Loss' = \hat{y} - y + \lambda \cdot ||w^2||$
Δw=d(Loss)/d(w);	$\Delta w = d(Loss)/d(w) + 2\lambda \cdot w$
w:=w-ηΔw;	w:=w-ηΔw-2ηλw

Regularization 对参数w有什么影响？

神经网络的“配件”

4. 过拟合---应对：

- Regularization

Before	After
Loss=ŷ-y;	$Loss' = \hat{y} - y + \lambda \cdot \|\|w^2\|\|$
Δw=d(Loss)/d(w);	$\Delta w = d(Loss)/d(w) + 2\lambda \cdot w$
w:=w-ηΔw;	w:=w-ηΔw-2ηλw

Regularization 对参数w有什么影响？

为了使Loss‘最小，w^2 部分要求w的值尽量平衡（why），和Loss共同影响w变化

神经网络的“配件”

4. 过拟合---应对：

- Regularization

Before	After
Loss=ŷ-y;	$Loss' = \hat{y} - y + \lambda \cdot \|\|w^2\|\|$
Δw=d(Loss)/d(w);	$\Delta w = d(Loss)/d(w) + 2\lambda \cdot w$
w:=w-ηΔw;	w:=w-ηΔw-2ηλw

[面试题] 什么叫做weight decay,与Regularization有何联系？

神经网络的“配件”

4. 过拟合---应对：

- Dropout

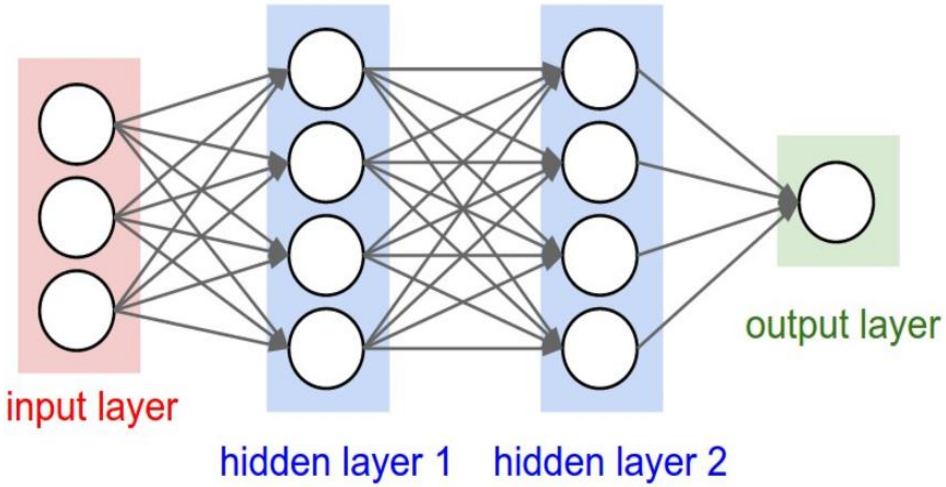

- [面试题] Dropout，Pooling 区别？

神经网络的“配件”

4. 过拟合---应对：

- Dropout

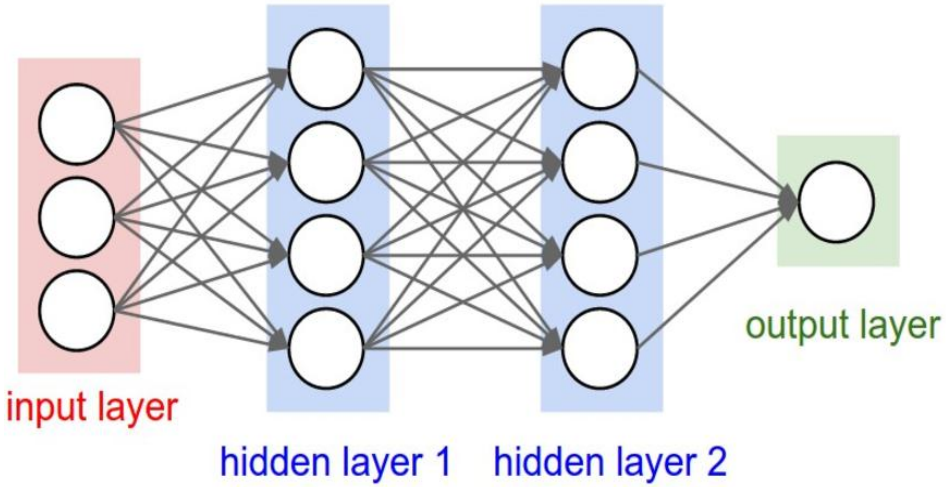

- [面试题] Dropout，Pooling 区别？

  Pooling的本质是降维，

  Droupout的本质是Regularization （为什么？）

神经网络的“配件”

4. 过拟合---应对：

- Fine-tuning

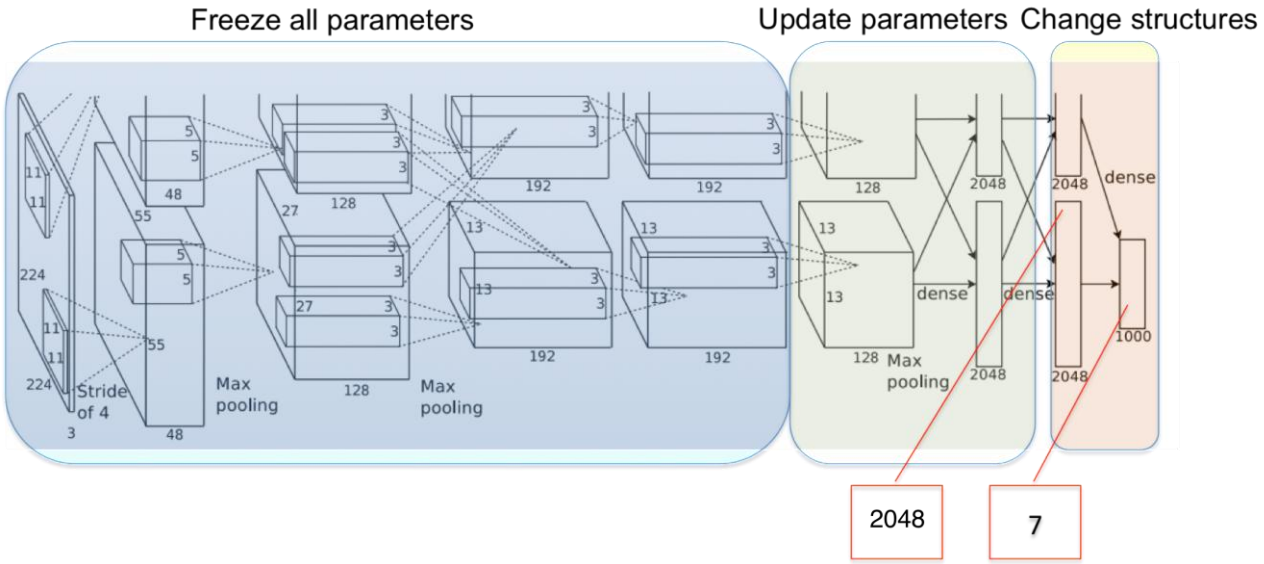

- 大部分的参数不用更新，实际的参数大量减少

总结

- 1. 神经网络起源：线性回归
- 2. 从线性到非线性
- 3. 神经网络的构建
- 4. 神经网络的“配件”

- 下节课预告：链式规则反向求导，SGD优化原理，卷积神经网络(CNN)各个layers介绍

总结

- 有问题请到课后交流区
  - 问题答疑： http://www.xxwenda.com/
    - 可邀请老师或者其他人回答问题
- 课堂QQ群438285995，微信群
- 讲师微博：weightlee03，每周不定期分享DL资料
- GitHub ID：wiibrew （课程代码发布）